

Por que Representações Simples Apresentam Performance Elevada?

Análise de Vazamento de Dados em Predição de
Atividade Quinase-Composto

Análise Exploratória de Dados

LNCC - Laboratório Nacional de Computação Científica

January 19, 2026

- 1 Contexto e Problema
- 2 Análise de Vazamento de Dados
- 3 Modelo Lookup Baseline
- 4 Desbalanceamento por Quinase
- 5 Consistência de Classe dos Compostos
- 6 Similaridade Química
- 7 Comparação de Cenários de Avaliação
- 8 Conclusões e Implicações

Contexto: Predição de Atividade Quinase-Composto

Objetivo:

- Predizer se um composto químico é **ativo** ou **inativo** contra uma quinase
- Classificação binária: ativo ($\leq 1\mu M$) vs inativo

Representações Utilizadas:

- **Quinases:** One-hot encoding
- **Compostos:** Morgan Fingerprints (2048 bits)

Características do Dataset

- 15.616 pares composto-quinase
- 8.131 compostos únicos
- 231 quinases únicas
- 56,8% ativos / 43,2% inativos

Split Utilizado

80% treino / 10% validação / 10% teste
(Split aleatório estratificado)

O Problema: Performance Inesperadamente Alta

Resultados Observados


Modelo	Accuracy	MCC
KNN	0.876	0.747
MLP	0.887	0.768

Questão Central:

Por que uma representação tão simples consegue performance tão elevada?

Expectativa: O problema deveria ser muito mais difícil!

Problema Crítico: Vazamento de Compostos



Descoberta Alarmante

- **64,7%** das linhas de teste têm composto vazado
- **36,6%** são duplicatas exatas (mesmo composto + quinase)

Detalhamento

- 820 de 1.355 compostos únicos do teste (60,5%) aparecem no treino
- Esses 820 compostos geram 64,7% das linhas

Consequência

O modelo pode estar **lembrando** ao invés

Hipótese: Modelo Simples de “Lookup”


Ideia: Se os modelos estão memorizando, um modelo que apenas “olha” a classe majoritária deveria ter performance similar.

Modelos Lookup Implementados

- 1 **Lookup por Composto:** Prediz a classe majoritária do composto no treino
- 2 **Lookup por Quinase:** Prediz a classe majoritária da quinase no treino
- 3 **Lookup Composto + Quinase:** Combina ambas as estratégias

Se o composto/quinase não existe no treino, prediz a classe global majoritária.

Resultados: Lookup vs KNN



Modelo	Acc	MCC
Lookup: Composto	0.787	0.577
Lookup: Quinase	0.750	0.510
Lookup: Comp+Quin	0.862	0.717
KNN (Original)	0.876	0.747



Conclusão

O modelo **Lookup simples** (apenas olha classe majoritária) tem performance **comparável** ao KNN!

Implicação

O KNN não está aprendendo padrões complexos — está memorizando!

Distribuição de Classes por Quinase



Quinases Trivialmente Previsíveis

Estatísticas Alarmantes

- **70,6%** das quinases são desbalanceadas (>80% uma classe)
- **45,6%** das linhas vêm de quinases extremamente desbalanceadas

Consequência

Para muitas quinases, o modelo pode simplesmente prever a classe majoritária e ter alta acurácia!



Exemplos Extremos

- Glycogen synthase kinase-3 beta: **100% ativos**
- Muitas quinases: **100% inativos**

Exemplo:

Se uma quinase tem 100% de compostos inativos, o modelo precisa apenas “aprender” que essa quinase → inativo.

Comportamento dos Compostos através de Quinases



Categoria	%
Uma quinase apenas	80,2%
Perfeitamente consistente	15,2%
Inconsistente	4,6%

Multi-quinase



76,7% dos compostos multi-quinase são perfeitamente consistentes!

Implicação Crítica

O **fingerprint do composto sozinho** carrega a maior parte do sinal preditivo!

Ou seja, só de olhar para o composto, já é possível saber se ele é ativo ou inativo para a maioria das quinases.

Similaridade Tanimoto: Teste vs Treino



Por que o KNN Funciona?

Similaridade	%
Muito similar (>0.8)	43,0%
Similar (0.6–0.8)	46,8%
Moderada (0.4–0.6)	5,8%
Baixa (<0.4)	4,4%

Descoberta

~**90%** dos compostos “novos” no teste têm vizinho muito próximo no treino!

Conclusão

O KNN funciona bem porque a maioria dos compostos de teste é **quimicamente muito similar** aos compostos de treino.

Três Cenários de Split

Cenário 1: Split Aleatório (Original)

Split 80/10/10 estratificado — **COM vazamento de dados**

Cenário 2: Split por Composto



Nenhum composto do teste aparece no treino — **Sem vazamento de compostos**

Cenário 3: Novo Composto + Nova Quinase



Compostos E quinases do teste nunca foram vistos no treino — **Generalização Verdadeira**

O Cenário 3 representa o caso de uso real: prever atividade para quinases e compostos completamente novos.

Resultados por Cenário de Avaliação



Performance Inflada vs Performance Real



	Reportado	Real	Queda
MCC			
KNN	0.747	0.407	-45%
MLP	0.768	0.275	-64%
Accuracy			
KNN	0.876	0.680	-22%
MLP	0.887	0.607	-32%

Conclusão

A queda **dramática** de performance confirma que os modelos estavam **MEMORIZANDO**, não aprendendo padrões generalizáveis!

Nota

O MLP sofre mais no cenário de generalização verdadeira (MCC cai para 0.275 — quase aleatório!)

- 1 **Vazamento Massivo:** 60,5% dos compostos de teste aparecem no treino
- 2 **Desbalanceamento Extremo:** 70,6% das quinases são trivialmente previsíveis
- 3 **Consistência de Compostos:** O fingerprint sozinho carrega o sinal preditivo
- 4 **Alta Similaridade:** 90% dos compostos de teste têm vizinho muito próximo
- 5 **Performance Inflada:** MCC cai de 0.77 para 0.27 em generalização real

Crítica Central

Modelos de triagem de quinases que não tiveram curadoria adequada dos dados podem estar superestimando drasticamente sua capacidade de generalização!

Recomendações

- Sempre verificar vazamento de compostos entre splits
- Avaliar desbalanceamento por quinase
- Usar splits que garantam generalização verdadeira
- Reportar métricas em cenários de compostos E quinases novos
- Comparar com baselines simples (Lookup)

Os modelos (KNN, MLP) **NÃO** estão aprendendo padrões complexos de interação quinase-composto.

Eles estão MEMORIZANDO devido a:

- ① Vazamento massivo de compostos
- ② Desbalanceamento extremo por quinase
- ③ Comportamento consistente dos compostos
- ④ Alta similaridade química ao treino

Esta análise é fundamental para validar qualquer modelo de predição de

Obrigado!

Perguntas?

LNCC - Laboratório Nacional de Computação Científica
Análise Exploratória de Dados