

Roteiro da Apresentação

Análise de Vazamento de Dados em Predição de Atividade Quinase-Composto

Guia Completo para Apresentadores e Leigos

LNCC - Laboratório Nacional de Computação Científica

January 19, 2026

Contents

1	Glossário de Termos Essenciais	2
2	Slides 1-2: Abertura	3
2.1	SLIDE 1: Capa	3
2.2	SLIDE 2: Sumário	3
3	Slides 3-4: Contexto e Problema	3
3.1	SLIDE 3: Contexto - Predição de Atividade Quinase-Composto	3
3.2	SLIDE 4: O Problema - Performance Inesperadamente Alta	4
4	Slide 5: Vazamento de Dados	4
4.1	SLIDE 5: Problema Crítico - Vazamento de Compostos	4
5	Slides 6-8: Modelo Lookup	4
5.1	SLIDE 6: Hipótese - Modelo Simples de “Lookup”	5
5.2	SLIDE 7: Resultados - Lookup vs KNN	5
5.3	SLIDE 8: Análise dos Resultados Lookup	5
6	Slides 9-10: Desbalanceamento por Quinase	6
6.1	SLIDE 9: Distribuição de Classes por Quinase	6
6.2	SLIDE 10: Quinases Trivialmente Previsíveis	6
7	Slides 11-12: Consistência dos Compostos	6
7.1	SLIDE 11: Comportamento dos Compostos através de Quinases	6
7.2	SLIDE 12: Análise de Consistência	7
8	Slides 13-14: Similaridade Química	8
8.1	SLIDE 13: Similaridade Tanimoto - Teste vs Treino	8
8.2	SLIDE 14: Por que o KNN Funciona?	8
9	Slides 15-18: Comparação de Cenários	8
9.1	SLIDE 15: Três Cenários de Split	9
9.2	SLIDE 16: Resultados por Cenário de Avaliação	9
9.3	SLIDE 17: Performance Inflada vs Performance Real	9

9.4 SLIDE 18: Queda Dramática de Performance	10
10 Slides 19-22: Conclusões	10
10.1 SLIDE 19: Resumo das Descobertas	10
10.2 SLIDE 20: Implicações para a Área	11
10.3 SLIDE 21: Conclusão Final	11
10.4 SLIDE 22: Obrigado / Perguntas	12
11 Perguntas Frequentes (FAQ)	12
11.1 “Por que o MCC é mais importante que a acurácia?”	12
11.2 “O que é o KNN exatamente?”	12
11.3 “O que é um MLP?”	12
11.4 “Isso significa que machine learning não funciona para descoberta de medicamentos?”	12
11.5 “Como deveríamos fazer o split correto?”	12
12 Referências Visuais	12

1 Glossário de Termos Essenciais

Antes de começar, vamos definir alguns termos que aparecerão frequentemente:

Termo	Definição Simples
Quinase	Uma proteína do corpo humano que funciona como um “interruptor” celular. Quando está defeituosa, pode causar doenças como câncer.
Composto químico	Uma molécula criada em laboratório que pode virar um medicamento.
Ativo	Um composto que consegue “desligar” ou “modificar” a quinase (potencial medicamento).
Inativo	Um composto que não tem efeito sobre a quinase.
Dataset	Conjunto de dados usado para treinar o modelo.
Treino/Teste	Dividimos os dados em duas partes: uma para “ensinar” o modelo (treino) e outra para verificar se ele aprendeu de verdade (teste).
Accuracy (Acurácia)	Porcentagem de acertos do modelo. Se acerta 87 de 100, tem 87% de acurácia.
MCC	Matthews Correlation Coefficient - uma métrica mais rigorosa que a acurácia. Vai de -1 (péssimo) a +1 (perfeito), onde 0 é aleatório.
Fingerprint molecular	Uma “impressão digital” do composto - um código numérico que representa sua estrutura química.
One-hot encoding	Uma forma de representar categorias como números. Ex: se temos 3 quinases (A, B, C), a quinase B seria representada como [0, 1, 0].

2 Slides 1-2: Abertura

2.1 SLIDE 1: Capa

O que dizer

“Boa tarde a todos. Hoje vou apresentar uma análise crítica sobre por que modelos de machine learning aparentemente simples conseguem resultados extraordinários na predição de atividade entre compostos químicos e quinases. Spoiler: a resposta não é que os modelos são geniais - é que há problemas sérios nos dados.”

2.2 SLIDE 2: Sumário

O que dizer

“Vamos passar por 8 tópicos principais. Começaremos entendendo o contexto do problema, depois vamos investigar diversos tipos de ‘vazamentos’ e vieses nos dados, e finalmente veremos o impacto real disso na performance dos modelos.”

3 Slides 3-4: Contexto e Problema

3.1 SLIDE 3: Contexto - Predição de Atividade Quinase-Composto

O que dizer

“Primeiro, vamos entender o problema que estamos tentando resolver. Quinases são proteínas muito importantes no nosso corpo - elas funcionam como ‘interruptores’ que controlam processos celulares. Quando uma quinase está defeituosa, pode causar doenças como câncer.

O objetivo é descobrir quais compostos químicos conseguem ‘desligar’ ou modificar essas quinases defeituosas. Se conseguirmos, temos um potencial medicamento.

Na prática, temos um problema de classificação binária: dado um composto e uma quinase, queremos prever se o composto é ATIVO (funciona contra a quinase) ou INATIVO (não funciona).

Usamos representações simples:

- Para quinases: one-hot encoding (basicamente um código de identificação)
- Para compostos: Morgan Fingerprints, que são como uma ‘impressão digital’ da molécula com 2048 números

Nosso dataset tem cerca de 15 mil pares composto-quinase, com 8 mil compostos diferentes testados contra 231 quinases diferentes.”

Analogia para Leigos

“Imagine que você tem 8 mil chaves diferentes (compostos) e 231 fechaduras (quinases). Queremos descobrir quais chaves abrem quais fechaduras, sem ter que testar todas as combinações no laboratório.”

3.2 SLIDE 4: O Problema - Performance Inesperadamente Alta

O que dizer

“Aqui está o mistério que nos motivou a fazer essa análise. Quando treinamos modelos simples como KNN e MLP com essas representações básicas, obtivemos resultados surpreendentemente bons:

- KNN: 87,6% de acurácia e 0,747 de MCC
- MLP: 88,7% de acurácia e 0,768 de MCC

Isso parece ótimo, certo? Mas há um problema: esse é um problema de biologia molecular extremamente complexo! Como é possível que representações tão simples resolvam um problema tão difícil?

Nossa hipótese: os modelos não estão realmente ‘aprendendo’ padrões biológicos - eles estão ‘trapaceando’ de alguma forma.”

Analogia para Leigos

“É como se um aluno tirasse 90% na prova sem estudar. Você desconfiaria que ele colou, certo? É exatamente isso que estamos investigando.”

4 Slide 5: Vazamento de Dados

4.1 SLIDE 5: Problema Crítico - Vazamento de Compostos

Gráfico: 01_leakage_analysis.png

O que dizer

“E encontramos a primeira ‘cola’: vazamento de dados!

Quando dividimos os dados em treino e teste, o ideal é que o teste contenha situações NOVAS que o modelo nunca viu. Mas descobrimos que:

- 64,7% das linhas de teste contêm compostos que JÁ APARECERAM no treino
- 36,6% são duplicatas EXATAS - o mesmo composto testado contra a mesma quinase!

Para ser mais preciso: dos 1.355 compostos únicos no teste, 820 deles (60,5%) também estão no treino. E como alguns compostos aparecem várias vezes, isso representa 64,7% das linhas.”

Analogia para Leigos

“Imagine uma prova de matemática onde 65% das questões são IDÊNTICAS às que o aluno já resolveu no dever de casa. Claro que ele vai tirar nota alta! Mas isso não significa que ele sabe matemática - significa que ele tem boa memória.

O mesmo acontece aqui: o modelo não está aprendendo a prever se um composto novo vai funcionar - ele está apenas ‘lembrando’ a resposta de compostos que já viu.”

5 Slides 6-8: Modelo Lookup

5.1 SLIDE 6: Hipótese - Modelo Simples de “Lookup”

O que dizer

“Para provar que os modelos estão memorizando, criamos modelos extremamente simples chamados ‘Lookup’ (que significa ‘consulta’ ou ‘olhar na tabela’).

Esses modelos não fazem nenhum cálculo sofisticado. Eles simplesmente:

1. **Lookup por Composto:** Olha qual foi a classe mais comum desse composto no treino e repete
2. **Lookup por Quinase:** Olha qual foi a classe mais comum dessa quinase no treino e repete
3. **Lookup Combinado:** Combina as duas estratégias

Se o modelo KNN/MLP estivesse realmente aprendendo padrões complexos, ele deveria ser MUITO melhor que esses modelos triviais.”

Analogia para Leigos

“É como se, em vez de resolver a conta de matemática, você apenas olhasse: ‘Hmm, toda vez que apareceu o número 7 na prova, a resposta foi B. Vou marcar B.’ Isso é o Lookup.”

5.2 SLIDE 7: Resultados - Lookup vs KNN

Gráfico: 02_baseline_comparison.png

O que dizer

“E aqui está o resultado chocante. Olhem o gráfico:

- O modelo Lookup Composto+Quinase, que APENAS consulta a classe majoritária, consegue 86,2% de acurácia e 0,717 de MCC
- O KNN, com todo seu algoritmo de vizinhos mais próximos, consegue 87,6% de acurácia e 0,747 de MCC

A diferença é mínima! Um modelo que simplesmente ‘lembra’ a resposta tem quase a mesma performance que o KNN.”

5.3 SLIDE 8: Análise dos Resultados Lookup

O que dizer

“Vamos analisar os números com calma:

O Lookup por Composto sozinho já consegue quase 79% de acurácia. Isso significa que, só de saber qual é o composto, já conseguimos acertar quase 80% das vezes!

Quando combinamos Composto + Quinase, chegamos a 86,2% - apenas 1,4 pontos percentuais abaixo do KNN.

A conclusão é clara: o KNN não está aprendendo interações complexas entre compostos e quinases. Ele está, essencialmente, memorizando.”

6 Slides 9-10: Desbalanceamento por Quinase

6.1 SLIDE 9: Distribuição de Classes por Quinase

Gráfico: 03_kinase_imbalance.png

O que dizer

“Agora vamos entender OUTRO problema: o desbalanceamento por quinase. O gráfico da esquerda mostra a distribuição de classes para cada quinase. Cada barra representa quantas quinases têm uma determinada proporção de ativos. Vejam os extremos:

- Muitas quinases têm 0% de ativos (todas as interações são inativas)
- Outras têm 100% de ativos (todas as interações são ativas)

O gráfico de pizza à direita resume: 70,6% das quinases são extremamente desbalanceadas!”

6.2 SLIDE 10: Quinases Trivialmente Previsíveis

O que dizer

“O que isso significa na prática? Significa que, para a maioria das quinases, o modelo não precisa aprender nada - basta chutar a classe majoritária! Por exemplo:

- Para a Glycogen synthase kinase-3 beta, 100% dos compostos são ativos. O modelo só precisa aprender: ‘se for essa quinase, responda ATIVO’
- Para muitas outras quinases, 100% são inativos. O modelo só precisa responder INATIVO

Isso explica por que o Lookup por Quinase sozinho já consegue 75% de acurácia!”

Analogia para Leigos

“Imagine uma prova de múltipla escolha onde, em 70% das questões, a resposta correta é sempre a letra A. Se você marcar A em tudo, já garante 70%!”

7 Slides 11-12: Consistência dos Compostos

7.1 SLIDE 11: Comportamento dos Compostos através de Quinases

Gráfico: 04_compound_consistency.png

O que dizer

“Agora vamos analisar o comportamento dos COMPOSTOS. O gráfico mostra a ‘consistência’ de cada composto.”

O que significa consistência?

Um composto é “consistente” quando ele se comporta da mesma forma contra **TODAS** as quinases que foi testado.

- Se um composto é **SEMPRE** ativo (contra todas as quinases testadas), ele é **consistente**
- Se um composto é **SEMPRE** inativo, também é **consistente**
- Se um composto é ativo contra algumas quinases e inativo contra outras, ele é **INCONSISTENTE**

O que dizer

“O gráfico de pizza mostra:

- 80,2% dos compostos foram testados contra apenas **UMA** quinase
- 15,2% são perfeitamente consistentes (sempre ativo OU sempre inativo)
- Apenas 4,6% são inconsistentes

”

Analogia para Leigos

“Pense em medicamentos do dia a dia:

- O paracetamol funciona para dor de cabeça, dor muscular, febre... É ‘consistente’ - funciona para várias coisas
- Alguns medicamentos são muito específicos - só funcionam para uma doença
- Raramente um medicamento funciona para gripe mas piora dor de cabeça - isso seria ‘inconsistente’

Nossos dados mostram que a maioria dos compostos é consistente: se funciona para uma quinase, provavelmente funciona para outras.”

7.2 SLIDE 12: Análise de Consistência**O que dizer**

“Vamos aos números dos compostos testados contra **MÚLTIPLAS** quinases: **76,7%** deles são perfeitamente consistentes!

O que isso implica?

Se um composto se comporta da mesma forma contra todas as quinases, então a informação mais importante está no **COMPOSTO**, não na quinase específica.

Ou seja: só de olhar o fingerprint do composto, já conseguimos prever se ele será ativo ou inativo - independente de qual quinase estamos testando!

Isso é problemático porque significa que o modelo não está aprendendo **INTERAÇÕES** específicas entre composto e quinase. Ele está apenas categorizando compostos como ‘bons’ ou ‘ruins’.”

8 Slides 13-14: Similaridade Química

8.1 SLIDE 13: Similaridade Tanimoto - Teste vs Treino

Gráfico: 05_similarity_analysis.png

O que dizer

“Mesmo para os compostos ‘novos’ no teste (aqueles que não aparecem no treino), existe outro problema: eles são MUITO SIMILARES aos compostos do treino.

O gráfico mostra a distribuição de similaridade de Tanimoto, que mede quão parecidos dois compostos são quimicamente (0 = totalmente diferentes, 1 = idênticos).

Para cada composto novo no teste, calculamos: qual o composto mais parecido no treino? Resultados:

- 43% têm similaridade $> 0,8$ (muito similares)
- 46,8% têm similaridade entre 0,6 e 0,8 (similares)
- Apenas 4,4% têm similaridade $< 0,4$ (realmente diferentes)

”

Analogia para Leigos

“Imagine que você treina um modelo para reconhecer fotos de gatos. No teste, você coloca fotos dos MESMOS gatos, só que de ângulos ligeiramente diferentes. Claro que o modelo vai acertar! Mas ele realmente aprendeu a reconhecer gatos em geral?”

8.2 SLIDE 14: Por que o KNN Funciona?

O que dizer

“Agora entendemos por que o KNN (K-Nearest Neighbors, ou K-Vizinhos Mais Próximos) funciona tão bem!

O KNN funciona assim: quando recebe um composto novo, ele procura os compostos mais PARECIDOS no treino e copia a resposta deles.

Se 90% dos compostos de teste têm um ‘vizinho’ muito similar no treino, então o KNN quase sempre vai encontrar a resposta correta - não porque entendeu a biologia, mas porque o composto de teste é quase idêntico a algo que ele já viu.

É como ter uma prova onde 90% das questões são reformulações de exercícios do livro. Se você decorou o livro, vai bem - mas não significa que entendeu a matéria.”

9 Slides 15-18: Comparação de Cenários

9.1 SLIDE 15: Três Cenários de Split

O que dizer

“Para provar definitivamente nosso ponto, criamos três cenários de avaliação:

Cenário 1 - Split Aleatório (Original):

Dividimos os dados aleatoriamente - é o que foi feito originalmente. Tem todos os problemas de vazamento que discutimos.

Cenário 2 - Split por Composto:

Garantimos que NENHUM composto do teste aparece no treino. Todos os compostos no teste são ‘novos’.

Cenário 3 - Novo Composto + Nova Quinase:

O cenário mais rigoroso: os compostos E as quinases do teste NUNCA foram vistos no treino. Isso simula o caso de uso REAL - quando queremos prever atividade para um medicamento totalmente novo contra uma quinase nunca estudada.”

9.2 SLIDE 16: Resultados por Cenário de Avaliação

Gráfico: 06_split_comparison.png

O que dizer

“E aqui está a prova definitiva. Olhem como a performance DESPENCA quando eliminamos o vazamento:

No split aleatório, tínhamos ~87% de acurácia e ~0,75 de MCC.

No split de generalização verdadeira (Cenário 3):

- KNN cai para 68% de acurácia e 0,41 de MCC
- MLP cai para 60% de acurácia e 0,27 de MCC

Notem também os tamanhos dos conjuntos de teste abaixo de cada barra - no Cenário 3 temos menos dados porque é mais restritivo.”

9.3 SLIDE 17: Performance Inflada vs Performance Real

Gráfico: 07_inflated_vs_real_performance.png

O que dizer

“Este gráfico resume tudo. À esquerda, o MCC; à direita, a acurácia.

As barras azuis mostram a performance ‘reportada’ (com vazamento).

As barras vermelhas mostram a performance ‘real’ (generalização verdadeira).

Vejam as setas com as porcentagens de queda:

- MCC do KNN cai 45%
- MCC do MLP cai 64%!

O MLP, que parecia ser o melhor modelo, sofre a maior queda! Isso sugere que ele era o mais dependente do vazamento.”

9.4 SLIDE 18: Queda Dramática de Performance

O que dizer

“Vamos aos números exatos:

MCC (métrica mais importante):

- KNN: 0,747 $\rightarrow$ 0,407 (queda de 45%)
- MLP: 0,768 $\rightarrow$ 0,275 (queda de 64%)

Acurácia:

- KNN: 87,6% $\rightarrow$ 68,0% (queda de 22%)
- MLP: 88,7% $\rightarrow$ 60,7% (queda de 32%)

Um MCC de 0,275 é muito próximo de aleatório! Significa que o MLP, no cenário real, praticamente não consegue distinguir ativos de inativos.

Isso confirma nossa hipótese: os modelos estavam MEMORIZANDO, não aprendendo.”

10 Slides 19-22: Conclusões

10.1 SLIDE 19: Resumo das Descobertas

O que dizer

“Vamos resumir as cinco descobertas principais:

1. **Vazamento Massivo:** 60% dos compostos de teste estão no treino
2. **Desbalanceamento Extremo:** 70% das quinases são trivialmente previsíveis
3. **Consistência de Compostos:** O fingerprint sozinho carrega o sinal preditivo
4. **Alta Similaridade:** 90% dos compostos de teste são muito similares ao treino
5. **Performance Inflada:** MCC cai de 0,77 para 0,27 em cenário real

Cada um desses problemas contribui para inflar artificialmente a performance.”

10.2 SLIDE 20: Implicações para a Área

O que dizer

“E aqui está a crítica central deste trabalho:

Modelos de triagem de quinases publicados na literatura, que não fizeram essa curadoria cuidadosa dos dados, podem estar DRASTICAMENTE superestimando sua capacidade de generalização!

Isso é grave porque esses modelos são usados para:

- Priorizar compostos para testes em laboratório
- Economizar tempo e dinheiro em pesquisa farmacêutica
- Tomar decisões sobre desenvolvimento de medicamentos

Se os modelos não generalizam de verdade, essas decisões podem estar erradas.

Recomendações:

1. Sempre verificar vazamento de compostos entre splits
2. Avaliar desbalanceamento por quinase
3. Usar splits que garantam generalização verdadeira
4. Reportar métricas em cenários de compostos E quinases novos
5. Sempre comparar com baselines simples como o Lookup

”

10.3 SLIDE 21: Conclusão Final

O que dizer

“Para concluir:

Os modelos KNN e MLP NÃO estão aprendendo padrões complexos de interação entre quinases e compostos.

Eles estão MEMORIZANDO devido a quatro fatores:

1. Vazamento massivo de compostos
2. Desbalanceamento extremo por quinase
3. Comportamento consistente dos compostos
4. Alta similaridade química ao treino

Esta análise é FUNDAMENTAL para validar qualquer modelo de predição de atividade quinase-composto. Antes de confiar em métricas impressionantes, precisamos garantir que o modelo está realmente generalizando.”

10.4 SLIDE 22: Obrigado / Perguntas

O que dizer

“Obrigado pela atenção. Estou à disposição para perguntas. Se quiserem explorar mais, todos os códigos e dados estão disponíveis, assim como os gráficos detalhados de cada análise.”

11 Perguntas Frequentes (FAQ)

11.1 “Por que o MCC é mais importante que a acurácia?”

A acurácia pode ser enganosa quando os dados são desbalanceados. Se 90% dos dados são de uma classe, um modelo que sempre responde essa classe tem 90% de acurácia mas não aprendeu nada. O MCC considera isso e só dá valores altos quando o modelo realmente distingue as classes.

11.2 “O que é o KNN exatamente?”

K-Nearest Neighbors (K-Vizinhos Mais Próximos) é um algoritmo simples: quando recebe um dado novo, ele procura os K dados mais parecidos no treino e usa a resposta da maioria. É como perguntar para seus vizinhos o que acharam de um restaurante - você confia na opinião de quem é mais parecido com você.

11.3 “O que é um MLP?”

Multi-Layer Perceptron é uma rede neural simples com algumas camadas de neurônios. É mais sofisticado que o KNN, mas ainda assim básico para os padrões atuais de deep learning.

11.4 “Isso significa que machine learning não funciona para descoberta de medicamentos?”

Não! Significa que precisamos ser MUITO cuidadosos com como preparamos os dados e avaliamos os modelos. Com curadoria adequada e splits corretos, podemos ter modelos que realmente generalizam - mas as métricas serão mais modestas e honestas.

11.5 “Como deveríamos fazer o split correto?”

O ideal é garantir que compostos e quinases no teste nunca apareçam no treino. Além disso, devemos garantir que compostos quimicamente similares também não apareçam em splits diferentes (cluster-based split). Isso simula o cenário real de uso.

12 Referências Visuais

- Slide 5: Gráfico 01_leakage_analysis.png
- Slide 7: Gráfico 02_baseline_comparison.png
- Slide 9: Gráfico 03_kinase_imbalance.png
- Slide 11: Gráfico 04_compound_consistency.png
- Slide 13: Gráfico 05_similarity_analysis.png
- Slide 16: Gráfico 06_split_comparison.png

- **Slide 17:** Gráfico 07_inflated_vs_real_performance.png

Roteiro preparado para a apresentação “Por que Representações Simples Apresentam Performance Elevada?” - LNCC